Máster Universitario en Investigación en Inteligencia Artificial

# K. Proyecto final

Ciencia de Datos y Aprendizaje Automático

---

Lorenzo José De La Paz Suárez

# Índice

**1. Introducción y descripción del problema** **2**
1.1. Necesidad de Negocio . . . . . 2

**2. Comprensión y preparado de datos** **2**
2.1. Comprensión . . . . . 2
2.2. Preparación . . . . . 5
2.2.1. Decisiones tomadas en base al EDA . . . . . 5
2.2.2. Pipelines . . . . . 7

**3. Modelado** **7**

**4. Evaluación** **7**
4.1. Experimentación . . . . . 7
4.2. Evaluación final . . . . . 8

**5. Conclusiones** **9**

**6. Resultado en Kaggle** **10**

# 1. Introducción y descripción del problema

A través de la presente memoria se va a desarrollar el proyecto final de la asignatura *Ciencia de Datos y Aprendizaje Automático.*

El caso de uso planteado se basa en el **diseño** y **desarrollo** de un **modelo predictivo** capaz de identificar cuándo un cliente podría abandonar los servicios de una entidad financiera a partir un conjunto de datos recopilados.
Para abordar este caso de uso, se disponen de los siguientes **ficheros**:

- Un conjunto de datos de **entrenamiento** de **8.000** instancias.
- Un conjunto de datos de **prueba** de **2.000** instancias.
- Un formato de **muestra** para el envío resultados a la plataforma Kaggle.

Para la realización de la práctica, se va a utilizar la metodología **CRISPDM** para abordar la conversión del Dato al Conocimiento.

## 1.1. Necesidad de Negocio

La fuga de clientes de las instituciones financieras es uno de los mayores desafíos, ya que la adquisición de nuevos clientes suele resultar mucho más costosa que retener a uno existente. Este fenómeno no solo afecta los ingresos directos del banco, sino también su estabilidad a largo plazo, al perder la confianza y la base de clientes.
La capacidad de **predecir** con antelación qué clientes tienen mayor probabilidad de abandonar la entidad se convierte en una **herramienta estratégica** esencial permitiendo focalizar esfuerzos, optimizar recursos en campañas de retención y, en definitiva, mejorar la relación con los clientes y la sostenibilidad del negocio.
Para el cumplimiento de este objetivo de negocio, se parte de un conjunto de datos sobre los clientes de la entidad financiera.

# 2. Comprensión y preparado de datos

Continuando con la metodología CRISPM, pasamos a una siguiente **fase de comprensión de los datos**, el cual tiene el objetivo de familiarizarse con los datos, identificando problemas de calidad y reconociendo datos de valor. Todo ello acorde con el objetivo de negocio que se persigue.
En esta fase, se va a realizar un **extenso análisis descriptivo** del conjunto de datos de entrenamiento que nos pueda servir como base de cualquier decisión a tomar para la generación de los consiguientes modelos de clasificación.

## 2.1. Comprensión

En el **Análisis Exploratorio de los Datos (EDA)**, he recopilado las siguientes **observaciones**:

- La variable *CustomerId* no presenta duplicados en el conjunto de entrenamiento. Además, no aporta información predictiva y podría introducir ruido, por lo que será **anulada**.
- La variable *Surname* tampoco aporta información predictiva, solamente ruido, por lo que será **anulada**.
- Pese a que se disponen de 13 columnas, hay **10 variables predictoras y una variable objetivo** (Exited).
- De las 10 variables predictoras, **8** son numéricas (4 son discretas, 2 son binarias y 2 continuas) y **2** variables categóricas.

| Variable | Tipología |
|---|---:|
| CreditScore | Numérica discreta |
| Geography | Categórica |
| Gender | Categórica |
| Age | Numérica discreta |
| Tenure | Numérica discreta |
| Balance | Numérica continua |
| NumOfProducts | Numérica discreta |
| HasCrCard | Numérica binaria |
| IsActiveMember | Numérica binaria |
| EstimatedSalary | Numérica continua |

Tabla 1: Descripción de las variables predictoras

- El conjunto de datos contiene 5.848 valores faltantes en sus columnas, y un **55,8 %** (4464) de las instancias (filas) presentan algún valor faltante.
  La **falta de valores** no es un problema "residual", sino que afecta a más de la mitad de las filas. Esto podría afectar a variables predictoras con mayor asociación con la variable objetivo.

| Variable | Número faltantes | Porcentaje |
|---|---:|---:|
| CreditScore | 1641 | 20,5 % |
| Balance | 1615 | 20,2 % |
| NumOfProducts | 976 | 12,2 % |
| EstimatedSalary | 832 | 10,4 % |
| Surname | 409 | 5,1 % |
| HasCrCard | 375 | 4,7 % |
| CustomerId | 0 | 0 |
| Geography | 0 | 0 |
| Gender | 0 | 0 |
| Age | 0 | 0 |
| Tenure | 0 | 0 |
| IsActiveMember | 0 | 0 |
| Exited | 0 | 0 |

Tabla 2: Número de valores faltantes y porcentaje sobre el total

- Las variables presentan **diferentes escalas**. Por ejemplo, la variable *CreditScore* oscila entre 350 y 850, mientras las variables sobre el salario (*Balance* y *EstimatedSalary*) en miles, y la edad (*Age*) en decenas. Este hecho requerirá una **estandarización** de los datos.

| | CreditScore | Age | Tenure | Balance |
|---|---|---|---|---|
| count | 6359 | 8000 | 8000 | 6385 |
| mean | 661,23 | 38,93 | 5.013875 | 76.929,67 |
| std | 95,88 | 10,38 | 2,89 | 62.292,13 |
| min | 350 | 18 | 0 | 0 |
| 25 % | 595 | 32 | 3 | 0 |
| 50 % | 664 | 37 | 5 | 98.009,13 |
| 75 % | 729 | 44 | 8 | 127.660,46 |
| max | 850 | 92 | 10 | 250.898,1 |

Tabla 3: Descripción de los datos de entrenamiento

| | NumOfProducts | HasCrCard | IsActiveMember | EstimatedSalary | Exited |
|---|---|---|---|---|---|
| count | 7.024 | 7.625 | 8.000 | 7.168 | 8.000 |
| mean | 1,54 | 0,71 | 0,51 | 100.057,17 | 0,20 |
| std | 0,57 | 0,45 | 0,5 | 57.441,73 | 0,40 |
| min | 1 | 0 | 0 | 11,58 | 0 |
| 25 % | 1 | 0 | 0 | 51.545,35 | 0 |
| 50 % | 2 | 1 | 1 | 100.129,07 | 0 |
| 75 % | 2 | 1 | 1 | 149.216,32 | 0 |
| max | 4 | 1 | 1 | 199.992,48 | 1 |

- La variable objetivo presenta un **desbalanceo (80 % frente a 20 %)**. Este hecho afectará a métricas como *accurancy*, así como a algoritmos que tienden a favorecer a la clase mayoritaria. Además, durante el entrenamiento, existe el **riesgo** de sobreajuste en la clase mayoritaria y subajuste de la clase minoritaria.

| Abandono | Instancias | Porcentaje |
|---|---|---|
| No | 6370 | 79,62 |
| Sí | 1630 | 20,38 |

Tabla 4: Balanceo de la variable Exited

- En la exploración de **correlaciones** entre los atributos numéricos y la variable a predecir, se encuentran variables con **mayor asociación** con la variable de clase. Concretamente, las variables *Age*, *isActiveMember*, *Balance* y *NumOfProducts*. El resto presentan correlaciones bajas ($\leq 0,081$).
  Este hecho será relevante para poner el **foco** en estas variables.

| Variable predictora | Coeficiente de correlación |
|---|---|
| Age | 0,286788 |
| IsActiveMember | -0,151504 |
| Balance | 0,122234 |
| NumOfProducts | -0,081740 |
| CreditScore | -0,023388 |
| Tenure | -0,023380 |
| HasCrCard | -0,012204 |
| EstimatedSalary | 0,011856 |

Tabla 5: Correlación con la variable clase

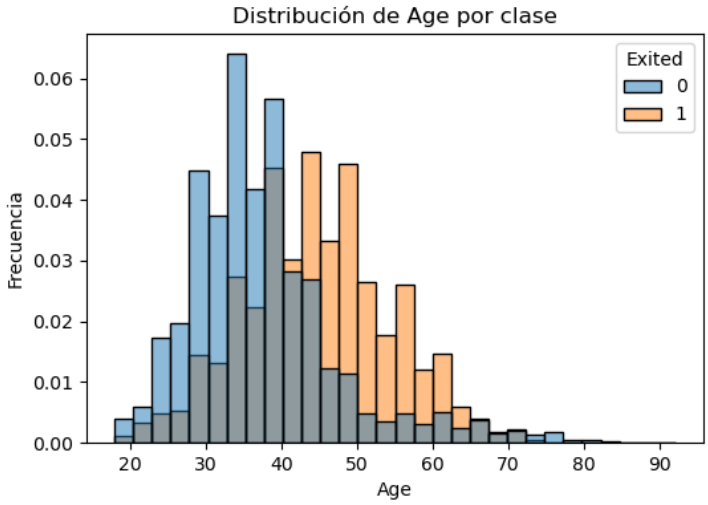


Figura 2: Distribución de la variable *Age* sobre la variable *Exited*

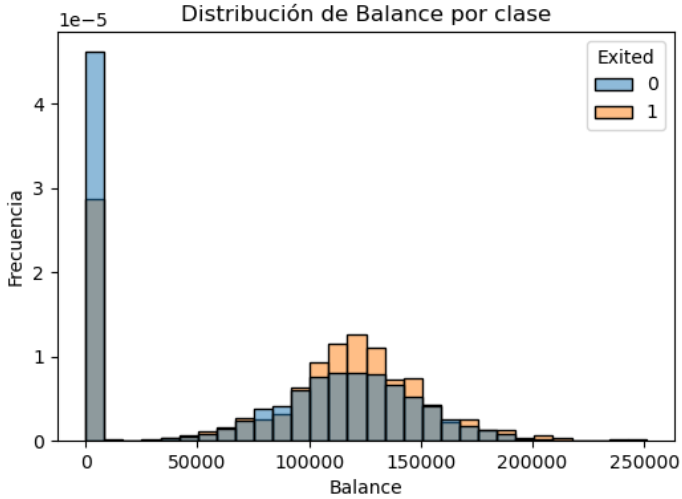


Figura 3: Distribución de la variable *Balance* sobre la variable *Exited*

- Las gráficas generadas en la distribución de las variables predictoras con la variable de clase, se destacan aquellas que tienen mayor correlación con la variable de clase.

## 2.2. Preparación

El objetivo de esta fase es **transformar los datos brutos en datos preparados** para ser modelados, con una selección, limpieza, construcción, integración y formato de los datos.

### 2.2.1. Decisiones tomadas en base al EDA

- **Eliminación** de las columnas que no aportan valor (**CustomerId** y **Surname**).
- **Gestión de los valores faltantes**: el importante número de valores ausentes (55,8 %), incluyendo variables clave (*Balance*, por ejemplo), no son ruido, sino que **aportan información** a la clase. Por ello, he creado **nuevas columnas binarias** bajo la nomenclatura *NA*. Esto nos permitirá contemplar el patrón "falta del dato" como **señal de comportamiento**.

$$\text{CreditScore_NA} = \begin{cases} 1 & \text{si CreditScore} = \text{NA} \\ 0 & \text{si CreditScore} \neq \text{NA} \end{cases}$$

- **Gestión de los valores fuera de rango y no contemplados**: los valores imposibles serán marcados como *NA*, permitiendo que la imputación lo convierta en un valor faltante. Si se encuentrara una categoría que no esté contemplada, se calificará como desconocida: "Unknown".
  En su conjunto, se definen las siguientes reglas de Negocio, las cuales, en un contexto real, se podrían adaptar (por ejemplo, existencia de más paises).

| **Variable** | **Regla** | **Descripción** |
|---|---|---|
| Age | $18 \leq \text{Age} \leq 110$ | Rango válido de edad |
| Tenure | $\text{Tenure} \geq 0$ | Antigüedad en años |
| CreditScore | $300 \leq \text{CreditScore} \leq 900$ | Contemplo valores del rango de entrenamiento |
| HasCrCard | $\text{HasCrCard} \in \{0, 1\}$ | Valor binario |
| IsActiveMember | $\text{IsActiveMember} \in \{0, 1\}$ | Valor binario |
| Balance | $\text{Balance} \geq 0$ | No puede haber saldos negativos |
| EstimatedSalary | $\text{EstimatedSalary} \geq 0$ | No puede haber salarios negativos |
| Geography | France / Spain / Germany | Cualquier otra categoría → "Unknown" |
| Gender | Male / Female | Categorías no válidas → "Unknown" |

Tabla 6: Reglas de negocio para validación de calidad de datos

- **Discretización de variables destacadas**
  - A partir de la variable numérica *Age*, se discretizará por **grupos funcionales** (joven, adulto, senior y mayor) para facilitar la interpretación y capturación de los datos. Desde el punto de vista del negocio, permitiría aplicar, por ejemplo, políticas de retención por tramo de edad.
    $$\text{Edad}_i = \begin{cases} \text{Joven} & \text{si } 18 \leq \text{Edad}_i < 30 \\ \text{Adulto} & \text{si } 30 \leq \text{Edad}_i < 45 \\ \text{Senior} & \text{si } 45 \leq \text{Edad}_i \leq 65 \\ \text{Veterano} & \text{si Edad}_i > 65 \end{cases}$$
  - A partir de la variable numérica *Balance*, se va a discretizar en función del sueldo para valorar el impacto económico, tomando los sueldos mayores de 100.000€(valor cerca de la media).
    $$\begin{cases} 1 & \text{si Sueldo}_i > 100\,000 \text{ €} \\ 0 & \text{si Sueldo}_i \leq 100\,000 \text{ €} \end{cases}$$
- **Variables y su imputación**: tanto para las variables numéricas como las variables categóricas se ha utilizado el **estándar de preparación de datos**.
  Esto es: para las numéricas, imputación mediante la mediana y el escalar estándar; para las categóricas, imputación mediante la moda y adecuación a valores binarios. Esta **estrategia** permite resolver:
  - Cubrir el problema de los valores ausentes, gracias a la imputación mediante la mediana y la moda respectivamente.
  - Estandarizar variables con rangos muy amplios, mitigándolo con *StandardScaler*.
  - La codificación OneHot nos permite evitar errores si aparecen categorías nuevas.
- **Nuevas interacciones**: de cara a aumentar el rendimiento de los modelos, he experimentado con una multitud de combinaciones de variables. Para más información, véase 7.

### 2.2.2. Pipelines

El uso de **pipelines** en *scikit-learn* me ha permitido **encapsular** todas las fases del preprocesamiento (imputación, escalado, codificación One-Hot, discretización y reglas de negocio) evitando fugas de información (*data leakage*).

El pipeline realizado se caracteriza por:

- Disponer de una función transformadora con **reglas de negocio**, conteniendo todos los pasos articulados para preparar los datos.
- Preparar las variables, tanto numéricas como categóricas, para su procesamiento.

Esta **estrategia** nos permite asegurar que las métricas sean más robustas y representen fielmente el rendimiento esperado del modelo en producción.

# 3. Modelado

En esta fase, he realizado el entrenamiento de diferentes modelos supervisados de clasificación binaria:

- **Regresión Logística**.
- **Random Forest**, por su capacidad para capturar relaciones no lineales y manejar desbalanceo.
- **Gradient Boosting**, por su capacidad para optimizar errores residuales y mejorar el rendimiento en problemas tabulares.
- **Modelos avanzados**: LightGBM, CatBoost, XGBoost

Todos los modelos los integré en un pipeline unificado para garantizar reproducibilidad, aislando fugas de datos (data leakage) y manteniendo consistencia entre entrenamiento y predicción.

# 4. Evaluación

Para la evaluación de los modelos, he utilizado **validación cruzada estratificada**, ya que la variable objetivo se encuentra **desbalanceada** (80 vs 20), y este enfoque nos mantiene la misma proporción de clases que en el conjunto original.

Durante la evaluación del modelo, he calculado las **probabilidades OOF (Out Of Fold)**, esto es, predicciones hechas solo en datos que el modelo no ha visto en cada iteración. Como algunos modelos dan probabilidades y otros dan una puntuación, las he reescalado a [0,1] para poder comparar todos en igualdad de condiciones.

Además, he calculado la métrica F1, tal y como se requiere para la evaluación.

## 4.1. Experimentación

Durante la **experimentación**, se ha utilizado la técnica **permutation performance**, técnica que se utiliza para reconocer las variables más destacadas de un modelo. En el *notebook*, he exportado los datos que he obtenido de la técnica para apoyo a la hora de decidir las variables y combinación de ellas.

**A modo resumen** (más detalle en el *notebook*), comento algunas de las combinaciones.

| **Interacción** | **Objetivo** | **Relevancia** |
|---|---|---|
| Age × IsActiveMember | Detectar si los clientes mayores e inactivos presentan mayor riesgo de abandono, así como el comportamiento de clientes jóvenes en función de su actividad. | Muy alta relevancia en todos los modelos |
| Age × Balance | Identificar si la combinación de edad y saldo revela patrones de abandono diferenciados entre clientes jóvenes y seniors. | Relevancia aceptable |
| Age × Tenure | Capturar la relación entre la edad del cliente y su antigüedad en la entidad. | Baja relevancia. Descartada. |
| Balance × EstimatedSalary | Analizar si clientes con alto salario y bajo balance (o viceversa) presentan mayor probabilidad de abandono. | Baja relevancia. Descartada. |
| HasCrCard × Age | Medir el riesgo de abandono según la edad y la posesión de tarjeta de crédito. | Baja relevancia. Descartada. |
| Age × NumOfProducts | Identificar diferencias de fuga entre clientes jóvenes y seniors con igual número de productos contratados. | Alta relevancia en todos los modelos |
| Age × Balance × IsActiveMember | Capturar perfiles de alto riesgo combinando edad, nivel de actividad y saldo, especialmente aquellos mayores con alto balance pero inactivos. | Baja relevancia. Descartada. |
| Germany × Age | Evaluar patrones de abandono relacionados con la combinación entre país de residencia Alemania y género. | Media relevancia en función del modelo |

Tabla 7: Algunas de las interacciones consideradas para el modelado

## 4.2. Evaluación final

He realizado una **tabla comparativa con el rendimiento de los modelos** sobre la métrica de rendimiento **F1** en el conjunto de test.

| Modelo | F1-mean | F1-std |
|---|---|---|
| Gradient Boosting | 0,567461 | 0,017909 |
| LGBM | 0,559373 | 0,012599 |
| CatBoost | 0,556486 | 0,007480 |
| XGBoost | 0,540564 | 0,011168 |
| Random Forest | 0,522469 | 0,012690 |
| Regresión Logística | 0,489602 | 0,013862 |

Tabla 8: Evaluación de los modelos

Como en la evaluación del ejercicio se toma la métrica F1, el modelo con mejor rendimiento es **GradientBoosting**.

Para la comparación visual y conjunta de los modelos, he recopilado los valores de rendimiento de los modelos para mostrar la **curva PR (Precision-Recall)**, la cual nos permite ver el comportamiento de éstos en distintas zonas del umbral.

Entre los modelos que disponen de mejor área bajo la curva (AP), son Gradient Boosting, CatBoost y LightGBM. Eso quiere decir que son los modelos más eficaces capturando clientes que abandonan sin generar demasiados falsos positivos.

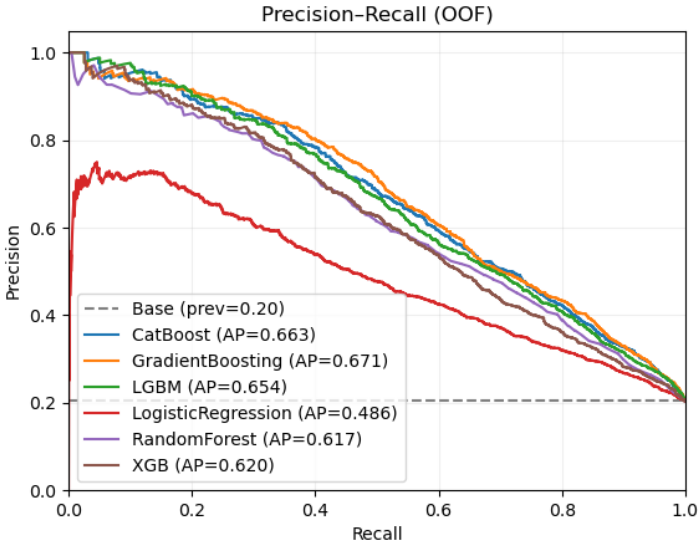


Figura 4: Gráfico de la curva Precision-Recall

Una vez seleccionado el mejor modelo, he **reentrenado** con todo el set de entrenamiento (conjuntos de entrenamiento y validación), de cara a que el modelo aproveche todos los datos para aprender el patrón y evitar cualquier pérdida de información.

La **matriz de confusión** es un método de visualización que nos permite conocer cómo acierta y falla un modelo de clasificación. La he calculado utilizando como base los datos de entrenamiento.

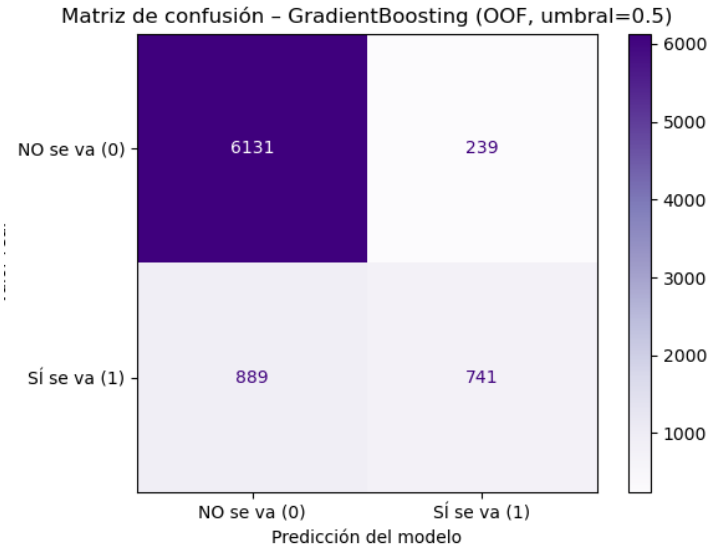


Figura 5: Matriz de confusión

# 5. Conclusiones

Entre otras, destaco las siguientes **conclusiones**:

- El análisis exploratorio permitió identificar **tres factores clave** del comportamiento de abandono:
  - El fuerte desbalanceo (80/20), que condiciona tanto la elección de métricas como de modelos.
  - La presencia de valores faltantes en más del 55 % de las instancias, lo que exigió un diseño de imputación y exploración de nuevas variables bajo terminología *_NA*.
  - La identificación de variables realmente influyentes — *Age*, *IsActiveMember*, *Balance* y *NumOfProducts*— que posteriormente mostraron alta relevancia en el modelado.
- La utilización de validación cruzada estratificada y **predicciones OOF** permitió obtener estimaciones realistas del rendimiento del modelo.
- Durante la experimentación se pudo constatar que los modelos basados en boosting (CatBoost, Gradient Boosting y LightGBM) capturan mejor las interacciones complejas entre variables y manejan adecuadamente el desbalanceo. Como ejemplo, son capaces de capturar y gestionar los valores faltantes, sin necesidad de la creación específica de columnas "_NA".
  **GradientBoosting** obtuvo la mejor métrica F1 en validación cruzada al contrastarlo en Kaggle y uno de los mejores valores de *Average Precision* en las curvas *Precision–Recall*, lo que lo convierte en el modelo más consistente para identificar clientes con riesgo de abandono.

Y las siguientes **reflexiones**:

- La utilización de la metodología **CRISPDM** me ha permitido ser un enfoque estructurado durante la realización de la práctica.
- La **fase de preprocesamiento de los datos** es la **más importante** del proyecto y la que me ha llevado **más tiempo**. La gran dedicación en el análisis, limpieza y transformación de los datos me ha permitido ver los avances - y a veces impedimentos - en la precisión de los modelos, cada vez que buscaba formas de mejorar la eficacia de ellos.
- Siempre que se pueda, la extracción del conjunto de entrenamiento debe de ser lo **más representativa y normalizada posible**. El escenario del trabajo encontrado ha sido adverso, con un desbalanceo alto y ciertas limitaciones añadidas (valores faltantes, no estandarizados, etc.).
- En la implementación técnica, el uso de pipelines integrados es **fundamental** para asegurar reproducibilidad y evitar fugas de información durante la validación. Si bien la encapsulación de reglas de negocio no fue pensado desde el inicio, sí que me ha ayudado durante la práctica para enfocarme en la mejora de la calidad del dato para los modelos.

# 6. Resultado en Kaggle

- Usuario: lorenzojos
- Github

**Score: 0.56310**

Private score: 0.61052